



ISSN: 1984-4751

Políticas Públicas Educacionais baseadas em evidências: tomada de decisão apoiada em algoritmos de mineração de dados a partir dos questionários da Avaliação Nacional da Educação Básica (ANEB)

Hugo Medeiros¹

Katarina Santiago¹

RESUMO

Este artigo objetiva demonstrar a criação de um modelo de algoritmo de conhecimento para suporte à decisão, que permite entender os perfis escolares dos estudantes e a relação entre esses perfis e o alcance dos resultados da política pública de educação no Estado de Pernambuco. Para isso foram utilizadas técnicas de aprendizagem de máquina para minerar quais respostas do questionário contextual, que é aplicado aos estudantes juntamente às provas de matemática e de língua portuguesa pela Avaliação Nacional da Educação Básica (ANEB), mais impactaram nos resultados dessas provas; e, posteriormente, estimar quais as relações entre os perfis estudantis e esses resultados a partir da observação das variações das notas dos testes de acordo com a variação em determinada variável selecionada anteriormente. Os resultados mostraram que há variáveis importantes comuns aos dois processos de aprendizagem, como a distorção idade-ano e a repetência; e variáveis exclusivas, como o gosto por matemática e os hábitos de leitura.

Palavras-chave: Perfil escolar. Pernambuco. Aprendizagem de Máquina. Tomada de Decisão. Políticas Públicas.

1. Introdução

Dentro do Mapa da Estratégia do Governo do Estado de Pernambuco, um dos objetivos estratégicos é o Pacto pela Educação (PPE). Essa iniciativa pública visa a “elevar o nível de escolaridade, a qualidade da educação pública e promover ações de incentivo a cultura” (SEPLAG, s/d). Neste sentido, o foco da política pública é o Ensino Médio, em virtude de esse

¹ Instituto de Gestão Pública de Pernambuco. Secretaria de Planejamento e Gestão de Pernambuco. hugo.vasconcelos@seplag.pe.gov.br ; katarina.santiago@seplag.pe.gov.br .

nível ser uma responsabilidade direta dos Estados (BRASIL, 1996); e utilizam-se como medidas de alcance do objetivo o Índice de Desenvolvimento da Educação Básica de Pernambuco (IDEPE) e o Índice de Desenvolvimento da Educação Básica (IDEB).

Os dois índices têm a mesma fórmula de medição, a mesma população-alvo e utilizam a mesma metodologia (teoria de resposta ao item). Contudo, diferenças como população de referência (o IDEB exclui escolas técnicas do cálculo), tipologia (até 2015, o IDEB era censitário), periodicidade (o IDEB é bianual), além de serem distintas as matrizes de referência das habilidades testadas na avaliação, fazem com que seja interessante para um Estado o acompanhamento dos dois índices. Assim, por exemplo, com o IDEPE o Estado poder comparar-se interna e anualmente; e, com o IDEB, nacionalmente, percebendo onde se coloca em relação a outras unidades federativas.

Como dito, os dois índices utilizam a mesma fórmula, qual seja a média das proficiências em língua portuguesa e em matemática, multiplicada pelo fluxo escolar. O fluxo escolar, por sua vez, é a média harmônica das aprovações em cada ano de uma dada etapa da Educação Básica.

Dentro do escopo do monitoramento da política pública estadual de educação, uma das questões que se coloca é o entendimento dos perfis escolares dos estudantes e a relação entre esses perfis e o alcance dos resultados, tendo em vista servir como *feedback* e insumo para reorientar o sistema educacional, de forma geral, e a tomada de decisão do gestor educacional, de forma mais específica.

Assim, a tomada de decisão na gestão pública deve caminhar, cada vez mais, para a modelagem racional e baseada em evidências, pois, quase sempre, os tomadores de decisão deparam-se com o cruzamento entre um portfólio enorme e heterogêneo de soluções disponíveis – tanto em criação próprio, quanto em *benchmarking* – e um número finito de recursos, o qual se torna ainda mais limitado devido à baixa discricionariedade de uso, e ao número de iniciativas legado recebidas pelos gestores públicos.

Na educação, esse cenário não é diferente e pode, até mesmo, ganhar contornos ainda mais complexos. Contudo, como afirma Lozano (2017), esse processo rumo a uma tomada de decisão baseada em evidências é uma construção coletiva, a qual se apoia, sobretudo, no esforço de os pesquisadores em responder perguntas relevantes a partir de evidências, independentemente do método:

É preciso fazer pesquisas com perguntas que, além de relevantes, sejam bem estruturadas. Ademais, os pesquisadores de Educação precisam se preocupar em utilizar métodos capazes de responder a essas perguntas e, independentemente da metodologia escolhida, é fundamental que sejam rigorosos (p. 158).

Deve-se destacar, então, que a aprendizagem de máquina é um desses métodos robustos o bastante para aprender evidências e trazer respostas para as perguntas. Pode, portanto, orientar a tomada de decisão numa política pública dentro da perspectiva da decisão orientada por algoritmos (CASTELLUCIA, MÉTAYER, 2019), a qual visa a reduzir a participação humana no processo de análise de dados em grandes bases, para concentrá-la no processo de tomada de decisão a partir das análises geradas pelo algoritmo, o que, espera-se, diminua o viés, gere eficiência na análise e garanta uma tomada de decisão mais orientada para evidências.

Para os autores (idem), um bom modelo de decisão orientada por algoritmos consegue garantir quatro características: integridade, ou a capacidade de reduzir o viés e aumentar a acuidade na estimativa do algoritmo; transparência, entendida como a abertura do código, seus parâmetros e base utilizada; inteligibilidade, na acepção de que os achados devem ser explicáveis e compreensíveis; e responsabilidade, na medida em que, ao mostrar as evidências do processo, permite que o tomador de decisão justifique as razões para suas decisões.

De forma mais específica, na classificação dos autores (idem), podemos enquadrar a proposta deste artigo como um

algoritmo de suporte à decisão (ASD) que objetiva melhorar o conhecimento ou a tecnologia disponível: algoritmos desse tipo são usados para gerar conhecimento novo, geralmente a partir da análise de fenômenos complexos. No caso de fenômenos complexos, esses algoritmos são essenciais, uma vez que eles podem ser usados para analisar grandes bases de dados e extrair conhecimento delas (p. 4, tradução dos autores).

Contudo, em virtude da complexidade do sistema educacional (JACOBSON, 2018), se colocam algumas dificuldades adicionais para identificação de padrões de aprendizagem e feedback corretivo para a política pública:

- **Gama de Prazos** (idem, 337): a disponibilidade de dados para traçar o perfil dos estudantes é difusa, pois ao longo do ano, numa periodicidade mensal, por exemplo, estão quase sempre indisponíveis, uma vez que os sistemas educacionais tendem a não coletá-los; porém, Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019

tecnologiasnaeducacao.pro.br - tecedu.pro.br

anual ou bianualmente, tendem a tornarem-se disponíveis todos de uma vez só, a partir das respostas dos questionários contextuais das avaliações externas – questionários esses que, usualmente, possuem um número elevado de respostas qualitativas, dificultando a análise, por questões como seleção de variáveis e a estimativa das relações e impactos delas sobre o resultado;

• **Dinâmica Ambiental Complexa**, fazendo com que os estudantes “aprendem em uma variedade de contextos: em ambientes de aprendizagem formais, com professores em escolas e universidades, e em ambientes de aprendizagem informais, como museus de ciência, mídia em massa, publicações impressas e, cada vez mais, fontes on-line mediadas pela internet” (idibem).

À complexidade da educação, soma-se a complexidade inerente à utilização de algoritmos de suporte à decisão (ASD) que geram conhecimento: a disponibilidade de dados, uma vez que eles precisam ser abundantes e retratar bem o fenômeno complexo ao qual se referem; e a larga curva de aprendizagem necessária para a modelagem e implementação de código, fazendo com que a técnica esteja pouco acessível entre os técnicos de governo responsáveis pela estrutura de suporte à decisão.

Neste contexto, este artigo objetiva contribuir com o estudo acerca do perfil escolar dos estudantes através do desenvolvimento de uma ASD de conhecimento, com uso de técnicas de aprendizagem de máquina para minerar quais variáveis dos questionários socioeconômicos são mais importantes e quais mais impactam as aprendizagens dos alunos; ou seja, quais variáveis mais impactaram nos resultados dos estudantes nas provas de matemática e de língua portuguesa da Avaliação Nacional da Educação Básica (ANEB) 2017; e, posteriormente, estimar quais as relações entre os perfis estudantis e os resultados, observando as variações nas notas dos testes de acordo com a variação em determinada variável selecionada anteriormente.

2. Embasamento Teórico

Na literatura, existem estudos qualitativos que fazem análises críticas com relação à capacidade do índice de desenvolvimento educacional medir, de fato, os resultados da política pública da educação, uma vez que:

mesmo que se considere a realização de avaliação externa sobre os resultados obtidos pelas escolas um importante indicador para que os gestores dos sistemas de ensino

Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019

tecnologiasnaeducacao.pro.br - tecedu.pro.br

possam corrigir problemas e reorientar decisões e percursos institucionais, as metodologias que desconsideram a diversidade cultural que permeia as redes de escolas não captam a efetiva dinâmica das unidades escolares, com base apenas nos resultados finais obtidos por testes padronizados. (MARTINS, 2001).

A esse respeito, Chirinéia e Brandão (2015) argumentam que o IDEB

é incipiente para determinar a qualidade educacional do país, na medida em que não se levam em conta os demais fatores que incidem sobre a qualidade, quais sejam: nível socioeconômico e cultural dos alunos; formação docente; valorização do magistério; condições materiais e imateriais de trabalho; gestão escolar; infraestrutura da escola, e insumos, entre outros.

Do outro lado da margem, os estudos quantitativos, em geral, tentam captar o impacto dessas variáveis no IDEB. Na revisão, com relação aos estudos quantitativos que analisaram a relação do perfil escolar dos estudantes e o Índice de Desenvolvimento da Educação, observou-se apenas o trabalho de Alves e Soares (2013), que considerou o perfil dos alunos e algumas características dos estabelecimentos de ensino. Para essa análise, os autores utilizaram dados da Prova Brasil, do Censo Escolar e do IDEB em um modelo de regressão múltipla. Os resultados mostraram que as escolas que atendem a alunos de menor nível socioeconômico têm piores resultados, mesmo com o controle de outras características. Além disso, as condições de infraestrutura e de complexidade da instituição também têm relação com o IDEB. Dessa forma, a política pública deve levar em conta no seu desenho tais limitações.

Neste contexto, este trabalho inova ao desenvolver um ASD de conhecimento a partir de um modelo de aprendizagem de máquina para, finalmente, analisar o impacto de variáveis qualitativas no resultado do IDEB; oferecendo uma saída para o abundante universo de críticas qualitativas ao exame, que contestam sua capacidade sem que, porém, consigam oferecer uma forma ordenada de compreensão para além de umas poucas características gerais, as quais não conseguem explicar o fenômeno no nível do indivíduo. A utilização de aprendizagem de máquina permite extrair, com boa precisão, um número maior de insights das bases de dados, a partir do nível do indivíduo, uma vez que as técnicas disponíveis de aprendizagem de máquina possuem maior capacidade de adaptação aos dados. A próxima seção explica o método utilizado.

3. Metodologia

A pesquisa utilizou os dados do questionário do ANEB 2017 como entrada para um modelo de aprendizagem de máquina, mais precisamente um algoritmo de florestas aleatórias, o qual realizou a mineração do perfil dos alunos.

Para Penteado, Bittencourt e Isotani (2019), cumpre destacar que esse tipo de dado é um dataset educacional aberto de nível micro, posto que focado no estudante, o qual permite, dentre outras ações, avaliar iniciativas públicas.

De acordo com o INEP (2018), a ANEB 2017 teve dois instrumentos: os testes de língua portuguesa e matemática, e os questionários contextuais, respondidos por alunos, professores e diretores (esses respondem sobre si e sobre a escola). No caso do questionário dos alunos, os jovens respondem sobre “ambiente e nível socioeconômico familiar, hábitos de estudo e de leitura, motivação, trajetória escolar, entre outros aspectos” (idem, p. 8).

Ao todo, o questionário dos alunos possui 60 questões, que vão do sexo, raça, idade, até perguntas sobre o dever de casa das disciplinas e hábitos de estudo, passando por questões de perfil socioeconômico, a exemplo de “Na sua casa tem televisão a cores?”, ou “Na sua casa tem banheiro?”.

As respostas às perguntas são binárias ou fatoriais. Mesmo quando poderia ser apresentada uma contagem (como na pergunta de banheiros), existe um valor máximo, do tipo “Sim, quatro ou mais”. Assim, temos uma base de dados cuja variável de interesse – a proficiência dos estudantes nos testes – é contínua, e as variáveis independentes são todas categóricas. Em adição, o número de casos, 43.167 no total (após retirada dos casos sem resposta), torna difícil a mineração do perfil dos estudantes.

Neste sentido, entendemos mineração de dados de forma semelhante à de Rigo e Cazella (2014), para quem a mineração pode ser definida como a extração de conhecimento implícito através de métodos específicos, tendo em vista identificar “padrões válidos, novos, potencialmente úteis e compreensíveis” (idem, p. 136).

Em virtude de oferecerem soluções para resolver problemas como esse, na última década, os algoritmos de Aprendizagem de Máquina (AM) voltaram a ganhar espaço, sobretudo, em virtude de sua capacidade de lidarem com muitos dados; de lidarem com dados de tipos diversos, inclusive categóricos; e por possuírem menos exigências quanto à distribuição

dos dados – em comparação com os métodos estatístico/computacionais tradicionais de avaliação, como as regressões, por exemplo.

Além disso, a utilização desses modelos tem-se mostrado eficiente e eficaz, em virtude de as máquinas apresentarem, usualmente, melhor desempenho do que os operadores humanos (no tocante a tempo e a consumo de recursos) em tarefas como seleção e classificação.

Neste sentido, Rand (2015, p. 52) resume bem as possibilidades de AM: “aprendizagem automática permite a pesquisadores de sistemas complexos inferir modelos em nível do indivíduo a partir de grandes conjuntos de dados, que podem ser usados para avaliar como uma nova política vai afetar as decisões destes indivíduos”.

Mas o que é AM? Em resumo, pode-se descrever a aprendizagem de máquina como um campo multidisciplinar de estudo que se debruça sobre como as máquinas resolvem tarefas de aprendizagem, sendo capazes de melhorar seu desempenho conforme treinam e ganham experiência na resolução do problema proposto (MITCHELL, 1997).

As máquinas podem aprender de duas formas, de acordo com a disponibilidade de informação a respeito da classificação dos dados, ou seja, a existência ou não de uma classe. Quadros de dados que possuem uma variável classe permitem à máquina uma aprendizagem supervisionada, uma vez que ela é capaz de identificar se acertou ou não; enquanto quadros de dados sem classe permitem aprendizagem não supervisionada, uma vez que a máquina consegue apenas agrupar instâncias (casos) de acordo com os atributos.

Para que a máquina possa resolver um problema na perspectiva de AM, é necessário estruturá-lo com uma tarefa, um indicador de desempenho e uma fonte de experiência de aprendizagem. Para este artigo, a tarefa é estruturar o perfil dos estudantes do 3º Ano do Ensino Médio da Rede Estadual, percebendo quais variáveis são mais importantes na construção do resultado em matemática e em língua portuguesa; o indicador de desempenho é o nível de erro da regressão, ou seja, o quão distantes estão os resultados reais dos testes e as previsões elaboradas pela máquina; e a fonte de experiência são os dados dos questionários contextuais da ANEB 2017, divididos em atributos, que são as variáveis explicativas, ou melhor, as respostas das questões contextuais, com as características do fenômeno sobre o qual se deseja aprender, e classe, a variável de interesse, sobre a qual se deseja aprender, que este caso são os resultados dos testes de proficiência.

Além da tarefa, do desempenho e da experiência, é necessário informar à máquina uma função de aprendizagem, que permite interpretar os dados e aprender a resolver a tarefa. Neste

Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019

artigo, é utiliza a técnica de Florestas Aleatórias: uma função de aprendizagem supervisionada que toma por base a construção aleatória de árvores de decisão, para aumentar a precisão da estimativa das variáveis importantes e a capacidade de predição do modelo.

Assim, essa função de aprendizagem usa a ideia de árvore da teoria dos grafos. Os grafos são um método de representação, gráfica ou escrita, de uma situação-problema através de vértices (pontos ou nós) e arestas (caminhos) (SCHEINERMAN, 2003). As árvores, por sua vez, são grafos conexos, ou seja, todos os pontos possuem conexões com outros, e não cíclicos, uma vez que não há caminho com retorno ao ponto inicial (idem).

As árvores de decisão, por sua vez, são árvores cuja decisão de divisão ou não se dá com base em testes de atributo, e que, para o caso em questão, são relevantes pois, ao estruturar de maneira simbólica um problema, ganham informações sobre ele. De maneira geral, a decisão de dividir ou não um nó – ou seja, de criar ou não arestas – envolve o nível de ganho de informação que aquela divisão trará sobre o problema. Logo, as árvores começam com um nó inicial, chamado raiz, no qual estão contidos todos os dados disponíveis. A raiz pode ser então dividida em ramos (arestas) de acordo com um teste de atributo, relacionado ao ganho de informação proveniente da partição. No fim, as arestas recebem novos nós, que trazem os dados divididos de acordo com as regras aprendidas sobre os atributos. Esse processo é repetido até que sejam formadas as folhas, que são nós terminais, nós de classificação, nos quais não há mais testes de atributo, uma vez que não se pode mais conseguir ganhos de informação, ou o ganho de informação é feito a um custo muito alto, como criar folhas com um total muito baixo de casos, ou tornar a árvore muito complexa (MITCHELL, 1997).

Por exemplo, considere a famosa árvore (idem) que representa o caminho da decisão de jogar ou não uma partida de tênis, começando pelas características climáticas (variável mais importante) e passando pelas características de umidade – caso o tempo esteja ensolarado – e de vento – caso o tempo esteja chuvoso. Assim, pode-se prever se haverá ou não uma partida perguntando-se “como está o tempo?” Se “nublado”, haverá jogo. Se “ensolarado”, faz-se a pergunta “Como está a umidade?” Se alta, tende a não haver jogo; se normal, tendência de haver o jogo. Caso a resposta à primeira pergunta seja “chuvoso”, pergunta-se sobre o vento. Caso esteja forte, tendência é não haver jogo; e caso esteja fraco, tendência é haver.

Percebe-se que, embora a função de aprendizagem possa ser complexa, por considerar tanto o ganho de informação quanto o custo do ganho, a representação gráfica do problema é relativamente simples, facilitando a avaliação e a tomada de decisão.

Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019

tecnologiasnaeducacao.pro.br - tecedu.pro.br

Além disso, segundo Mitchell (1997), esta função de aprendizagem é capaz de se acomodar a uma classificação categórica, sem a necessidade de transformar em binárias as variáveis de interesse, bem como permite a utilização de atributos categóricos, e é robusto o bastante para produzir classificações acuradas mesmo quando há algum nível de erro nos dados.

Finalmente, como dito anteriormente, não será utilizada a técnica originária de árvores de decisão, e, sim, a técnica de florestas aleatórias. Observa-se que as florestas aleatórias são uma técnica de aprendizagem conjunta, ou seja, uma forma de aprendizagem em que a máquina é submetida a vários modelos e aprende considerando esses modelos de maneira conjunta.

Em resumo, esse processo de aprendizagem conjunta pode ocorrer de duas formas: incremental (*boosting*) ou paralela (*bagging*). No primeiro, os modelos são acrescentados progressivamente, fazendo com que cada geração seja mais precisa que a anterior; no segundo, os modelos não são acrescentados, mas, sim, elaborados paralelamente, com amostras diferentes dos dados, fazendo com que a máquina aprenda através da “votação” da classificação entre os modelos (ou seja, a moda) ou da média, em casos de regressão.

De acordo com Zhou (2012), a força dos métodos paralelos vem da independência das aprendizagens, o que tende a reduzir a variância e o viés da aprendizagem, moldando-se melhor a aprendizagens instáveis, ou seja, quando as variáveis são não lineares, como as variáveis qualitativas do questionário ANEB, e/ou quando a amostragem tende a alterar bastante os resultados – o que também é de se esperar, no caso específico, em virtude de estarmos trabalhando com respostas individuais de estudantes a 60 questões diferentes.

As florestas aleatórias enquadram-se, decerto, em modelos paralelos, uma vez que a aprendizagem se dá por meio da criação de árvores de decisão que selecionam amostras probabilísticas dos atributos a cada geração (BREIMAN, 2001). Assim, ao criar uma floresta com novos atributos a cada rodada, a técnica permite que cada árvore desenvolva uma aprendizagem especializada nos atributos que foram selecionados aleatoriamente.

Em relação à implantação da solução, foi utilizada linguagem de programação R, em seu ambiente de desenvolvimento integrado R Studio, com o uso do pacote *randomForest*, cujo algoritmo tem por base o modelo de florestas aleatórias sugerido por Leo Breiman (idem).

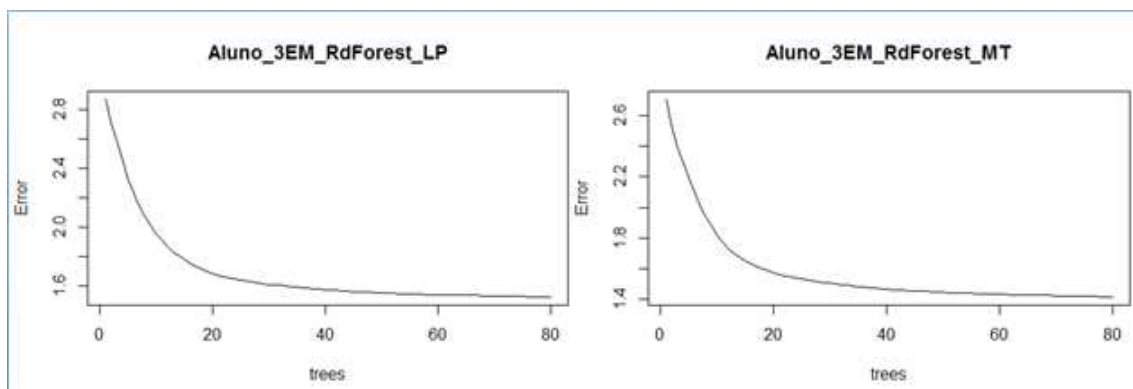
Como dito anteriormente, foram utilizados apenas casos em que todas as respostas do questionário estavam disponíveis. Além disso, foram usadas as proficiências padronizadas nos testes de língua portuguesa e matemática. Finalmente, os dados foram divididos de forma

aleatória em treino (70%) e teste (30%) tendo em vista diminuir a possibilidade de superajuste na aprendizagem de máquina

4. Análise e Discussão dos Dados

Na mineração do perfil, foram criadas 80 árvores para língua portuguesa e 80 árvores para matemática; e, em ambos os casos, foram seleccionadas aleatoriamente 17 variáveis em cada árvore. Para língua portuguesa, a média dos resíduos quadráticos foi 1.52, e a percentagem explicada da variância foi de 25.52%; para matemática, respectivamente, 1.41 e 26.83%. Pelos gráficos observou-se que a saturação da aprendizagem deu-se por volta de 20 árvores, não havendo melhorias marginais relevantes daí em diante, conforme mostram os gráficos abaixo:


Figura 1. Evolução do erro de classificação de acordo com o total de árvores.



Fonte 1. Elaboração dos autores.

Em relação às questões que mais intensamente se relacionam com os resultados nos testes de língua portuguesa e matemática, foi utilizada a estatística %IncMSE, a qual indica qual a variação no Erro Quadrático Médio quando a variável é retirada do modelo – o que é uma forma de identificar quais as variáveis mais importantes.

Figura 2. Alteração no Erro quadrático médio quando da remoção de determinada variável do modelo, para as duas disciplinas.



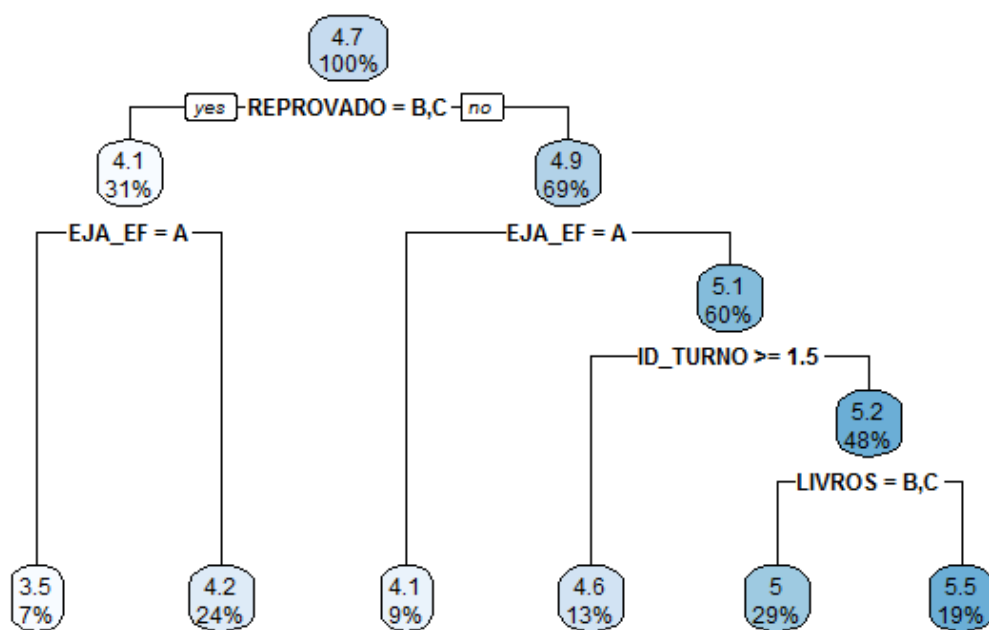
Fonte 2. Elaboração dos autores.

Pelos gráficos de importância das variáveis, observa-se que os perfis dos resultados são consideravelmente diferentes, uma vez que, para língua portuguesa, a variável mais importante é se o(a) estudante cursou o ensino fundamental no EJA (>35% de variação no MSE quando a variável é retirada); e, para matemática, se o(a) estudante gosta ou não da disciplina (~45% de variação no MSE).

Porém, algumas variáveis aparecem nas duas listas, como a própria EJA_EF (que é a terceira na lista de MT); ID_TURNO; IDADE, ID_SERIE, variável que muda de acordo com se o ensino é integral ou não; e REPROVADO, variável que indica se o (a) estudante possui ou não reprovação.

Em virtude dessas diferenças, e para aumentar a compreensão sobre os perfis dos (as) estudantes, foram criadas árvores isoladas, apenas com as variáveis mais importantes (ou seja, %IncMSE \geq 15%). Ficando assim as listas de variáveis usadas na construção das árvores finais: LP ~ EJA_EF + ID_TURNO + REPROVADO + MÍDIAS_TELAS + LIVROS + IDADE + ID_SERIE + DIDATICOS_LP; e, MT ~ MT_GOSTO + SEXO + EJA_EF + ID_TURNO + IDADE + REPROVADO).

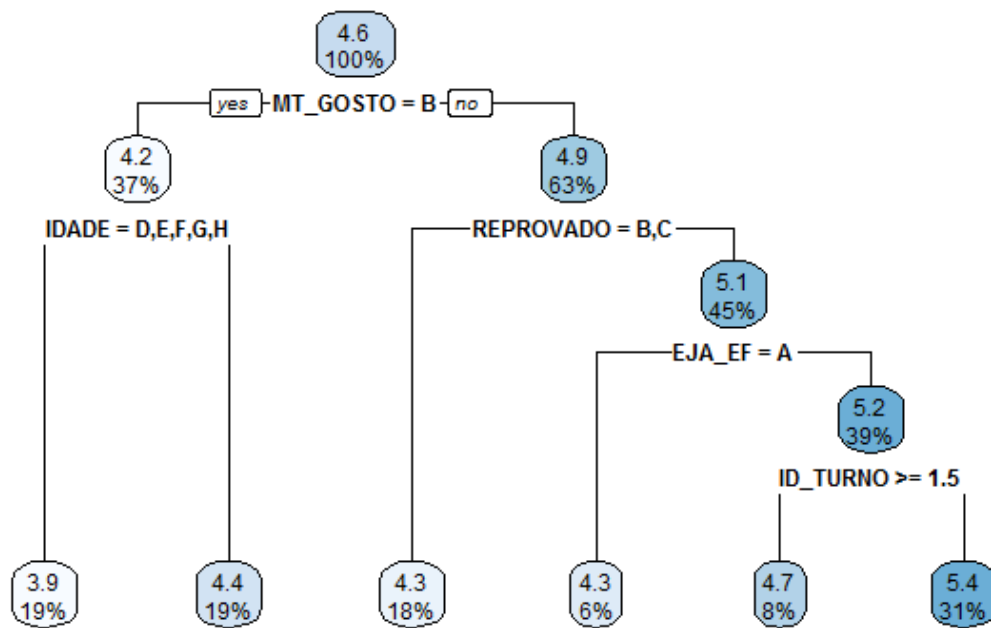
Figura 3. Árvore de decisão com as variáveis mais importantes para língua portuguesa.



Fonte 3. Elaboração dos autores.

Como é possível notar, estudantes com reprovação B (Sim, uma vez) ou C (Sim, mais de uma vez), apresentam, na média, notas de língua portuguesa menores que aqueles que nunca tiveram reprovação. O próximo split, que aparece nos dois lados da árvore, mostra as diferenças entre aqueles que fizeram o ensino fundamental na Educação de Jovens e Adultos (A = Sim) e aqueles que não. Em seguida, os turnos vespertino e noturno apresentam notas piores que o diurno. Finalmente, estudantes que leem livros com pouca frequência ou que não leem (LIVROS = B, C, respectivamente), tendem a apresentar notas menores do que aqueles que leem com frequência. Em resumo, estudantes que já apresentaram reprovação e que fizeram EF no EJA tendem as menores notas (3.5); enquanto estudantes que não reprovaram, não fizeram EF no EJA, estudam pela manhã e leem livros tendem as maiores notas (5.5).

Figura 4. Árvore de decisão com as variáveis mais importantes para matemática.



Fonte 4. Elaboração dos autores.

Aqui, temos que o gosto por matemática encaminha para árvores de valores mais altos (uma vez que MT_GOSTO = B representa ausência de gosto pela disciplina). As idades mais altas que 17 anos (D representa 18 anos, E, 19 anos...) tendem a notas mais baixas. Do outro lado da árvore, estudantes que possuem reprovações ou que concluíram o EF no EJA também possuem notas mais baixas, enquanto, mais uma vez, estudantes que estudaram no turno diurno tendem às maiores notas².

5. Conclusões e/ou Propostas

A avaliação do ferramental à luz do modelo proposto por Castellucia e Métayer (2019) mostra que o algoritmo é adequado ao uso para tomada de decisão, pois é possível verificar a

² Destacam-se, nos modelos finais das árvores, a ausência de algumas variáveis importantes, como sexo para MT, por exemplo. Possivelmente, a ausência dessas variáveis no modelo simbólico final indicam que a carga fatorial dessas variáveis pode estar sendo captadas por outras – como, no exemplo citado, o gosto por estudar matemática. Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019

integridade da análise pela redução do erro a níveis baixos; a transparência, pela possibilidade de compartilhar o código da solução, com seus respectivos parâmetros, os quais foram aplicados a uma base aberta, de domínio público; a inteligibilidade, pela característica do algoritmo escolhido, que permite interpretação, indicando, inclusive, os pesos relativos das variáveis; e a responsabilidade, já que é claro ao tomador de decisão qual o feixe de variáveis importantes e como elas se relacionam com os resultados almejados pela política pública.

Quanto à análise em si, de maneira geral, observamos repetições nos perfis, sendo possível identificar um espaço de atuação para políticas públicas mais tradicionais, conectadas ao combate à distorção e à reprovação, evitando, especialmente, que as reprovações e distorções sejam tão frequentes ao ponto de estudante necessitar concluir o fundamental com a EJA; e também espaço para atuação com políticas públicas focalizadas em padrões individuais, usando, por exemplo, economia comportamental, para incentivar os hábitos de leitura, no caso de língua portuguesa, e o gosto por estudar matemática, no caso dessa disciplina.

Todavia, o algoritmo consegue chegar ao nível preditivo, e não ao prescritivo. Assim, embora indique importâncias, relações e expectativas de impactos, não é capaz de apontar quais opções estão disponíveis, tampouco quais são mais apropriadas. Isso exige, sem dúvidas, que o tomador de decisão, através de si ou de outra ferramenta, mapeie as ações e opções disponíveis, e selecione aquela que lhe seja mais adequada para modificar uma variável secundária e modificar o resultado.

Como colocado na introdução, a construção de uma cultura de políticas públicas baseadas em evidência é uma construção coletiva, com sementes e frutos colocados por diferentes pesquisadores, ao longo do processo. Então, para prosseguimento dos estudos, cumpre, uma vez que o mapeamento de variáveis encontra-se estruturado, encaminhar para o passo de identificação, catalogação, descarte e fortalecimento (ou, quiçá, formulação) de soluções e de políticas públicas capazes de agir sobre as variáveis identificadas, fazendo com que o uso de inteligência artificial possa refletir na melhoria tanto do fazer pedagógico, quando das políticas públicas educacionais. Assim, tem-se potencial para completar o ciclo e o modelo de aprendizagem de máquina cumprir seu papel como um ADS de conhecimento.

6. Referências Bibliográficas

- Alves M. T. G. e Soares J. F. Contexto escolar e indicadores educacionais: condições desiguais para a efetivação de uma política de avaliação educacional. **Educação e Pesquisa**, São Paulo, v. 39, n. 1, p. 177-194, jan./mar. 2013.
- Breiman, L. Random Forests. **Machine Learning**, n. 45, p. 5-32, 2001.
- Chirinéa, A. M. e Brandão, C. da F. O IDEB como política de regulação do Estado e legitimação da qualidade: em busca de significados **Ensaio: avaliação de política pública Educacional**, Rio de Janeiro, v. 23, n. 87, p. 461-484, abr./jun. 2015.
- Castelluccia, C.; Le Métayer, D. **Understanding algorithmic decision-making: Opportunities and challenges**. Bruxelas: União Europeia, 2019.
- Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Microdados da Aneb e da Anresc 2017**. Recuperado em 31 de outubro de 2018, de < <http://portal.inep.gov.br/basicalevantamentosacessar>>, 2018.
- Jacobson, M. A educação como sistema complexo: implicações para a pesquisa educacional e políticas. Furtado, B.; Sakiwski, P.. Tóvili, M. **Modelagem de sistemas complexos para políticas públicas**. Brasília, Brasil, IPEA, p. 335-350, 2015.
- Lozano, P. O PAPEL DOS PESQUISADORES DA EDUCAÇÃO NA PRODUÇÃO E DIFUSÃO DE PESQUISA EDUCACIONAL. : Fundação Santillana. **CAMINHOS PARA A QUALIDADE DA EDUCAÇÃO PÚBLICA: IMPACTOS E EVIDÊNCIAS**. São Paulo: Fundação Santillana, 2017.
- Martins, A. M. A descentralização como eixo das reformas do ensino: uma discussão da literatura. **Educação & Sociedade**, ano XXII, no 77, Dezembro/2001.
- Mitchell, T. **Machine Learning**, McGraw-Hill Science/Engineering/Math, 1997.
- Penteado, B.E., Bittencourt, I. I, Isotani, S. Análise exploratória sobre a abertura de dados educacionais no Brasil: como melhorar o ecossistema de dados na Web? **Brazilian Journal of Computers in Education** (Revista Brasileira de Informática na Educação - RBIE), 27(1), 175-195. DOI: 10.5753/RBIE.2019.27.01.175, 2019.
- Pernambuco. **Lei nº 16.379**, de 6 de junho de 2018 - Altera a Lei nº 12.985, de 2 de janeiro de 2006, que dispõe sobre o Sistema Estadual de Informática de Governo - SEIG. Recife, Brasil, Assembleia Legislativa de Pernambuco, 2018.
- Pernambuco. **Mapa da Estratégia 2015-2018**.< <https://www.seplag.pe.gov.br/servicos-da-seplag/65-mapa-da-estrategia>>, s/d.
- Revista Tecnologias na Educação – Ano 11 – Número/Vol.31 – Edição Temática XII–IV Congresso sobre Tecnologias na Educação -Ctrl+e 2019
- tecnologiasnaeducacao.pro.br - tecedu.pro.br

Rand, W. Sistemas Complexos: conceitos, literatura, possibilidades e limitações. Furtado, B.; Sakiwski, P.; Tóvili, M. **Modelagem de sistemas complexos para políticas públicas**. Brasília, Brasil, IPEA, p. 43-63, 2015.

Rigo, J.S., Cazella, S. C. Aplicações de Mineração de Dados Educacionais e Learning Analytics com foco na evasão escolar: oportunidades e desafios Brazilian **Journal of Computers in Education** (Revista Brasileira de Informática na Educação - RBIE), 22(1), 132-146, 2014.

Scheinerman, E. **Matemática Discreta**: Uma Introdução, São Paulo, Pioneira Thomson Learning, 2003.

Zhou, Z-H. **Ensemble Methods**: Foundations and Algorithms, Nova Iorque, CRC Press, 2012

Recebido em Novembro 2019

Aprovado em Novembro 2019